

Projet 3 Apprentissage Statistique : Méthodes non paramétriques

Killian Le Milbeau

Version actualisée — 21 septembre 2026

Table des matières

Introduction	2
1 Analyse des données	3
1.1 Description	3
1.2 Standardisation et normalisation	4
1.3 Analyse en composantes principales	5
2 Une classe pour chaque tumeur	6
2.1 LDA	6
2.2 k -plus proches voisins	7
2.3 Arbres de décision, agrégation de forêts aléatoires	8
2.4 AdaBoost	11
3 Seule contre tous	12
3.1 ACP	12
3.2 LDA	13
3.3 k -plus proches voisins	13
3.4 Arbres de décision	15
3.5 AdaBoost	18
4 Conclusion	19

Introduction

Nous nous intéressons à la classification de cinq types de tumeurs à partir de leurs profils d'expression génique. Les données étudiées proviennent du jeu RNA-Seq PANCAN associé au projet *The Cancer Genome Atlas*. Les fichiers fournis contiennent 801 observations et 20 531 variables, correspondant aux dimensions décrites dans la fiche du jeu de données UCI¹.

Nous conservons les deux objectifs du projet initial : distinguer les cinq types de tumeurs, puis identifier les tumeurs BRCA parmi les quatre autres types réunis. Nous comparons l'analyse discriminante linéaire (LDA), les k -plus proches voisins, les arbres de décision, les forêts aléatoires et AdaBoost. La LDA, méthode paramétrique, sert ici de référence dans un projet principalement consacré aux méthodes non paramétriques.

Protocole d'évaluation. La règle d'échantillonnage du notebook conserve chaque observation avec une probabilité de 0,5, avec la graine 74909311. Elle produit un sous-échantillon de **420 observations**. Un découpage stratifié, fixé avec la graine 42, attribue **336 observations à l'entraînement** et **84 au test**. Tous les modèles utilisent les mêmes observations de test ; le passage au problème binaire ne crée pas de nouveau découpage.

Les hyperparamètres sont sélectionnés sur l'entraînement par validation croisée stratifiée à cinq plis. Les transformations intégrées aux pipelines sont ajustées dans chaque pli : filtrage des variables presque constantes et standardisation pour les voisins ; filtrage et ACP pour AdaBoost. Les graphiques exploratoires portant sur les expressions géniques utilisent uniquement l'entraînement dans cette version du notebook.

Lecture des résultats. L'*accuracy* est la proportion de prédictions correctes. Le F_1 combine précision et rappel. En multiclasse, le F_1 *macro* donne le même poids à chaque classe et sert à sélectionner les hyperparamètres ; le F_1 *pondéré* tient compte des effectifs. En binaire, BRCA est la classe positive et la sélection maximise son F_1 . Dans toutes les matrices, les lignes indiquent les classes réelles et les colonnes les classes prédites.

Ce rapport reprend les résultats de l'exécution fournie dans `Cancer.ipynb`. Les scores de test présentés avec davantage de décimales sont recalculés à partir de ses matrices de confusion. Il ne constitue pas une nouvelle validation externe. Les données ayant déjà été explorées au cours du projet, les performances doivent être interprétées comme des résultats expérimentaux internes.

¹S. Fiorini (2016), *gene expression cancer RNA-Seq*, UCI Machine Learning Repository, doi:10.24432/C5R88H.

1 Analyse des données

1.1 Description

Les deux fichiers, `data.csv` et `labels.csv`, sont alignés sur les identifiants d'échantillons. Les expressions géniques sont numériques et les vérifications effectuées ne mettent pas en évidence de valeur manquante ou infinie. Les noms de colonnes, de `gene_0` à `gene_20530`, sont conservés lors du chargement.

Les 420 observations retenues se répartissent entre cinq classes. BRCA est la classe la plus représentée, avec 150 observations, tandis que COAD n'en compte que 32. Le découpage stratifié préserve approximativement cette répartition.

Classe	PRAD	LUAD	BRCA	KIRC	COAD
Localisation	Prostate	Poumon	Sein	Rein	Côlon
Sous-échantillon	72	80	150	86	32
Entraînement	58	64	120	69	25
Test	14	16	30	17	7




FIGURE 1 – Répartition des cinq types de tumeurs dans les 420 observations.

Chaque observation est décrite par **20 531 expressions géniques**. Le nombre de variables est donc très supérieur au nombre d'observations d'entraînement. Cette situation rend particulièrement utiles la réduction de dimension, la régularisation des modèles et une évaluation séparée de leur ajustement.

Le déséquilibre entre les classes justifie le suivi du F_1 macro. Une bonne accuracy peut masquer une performance moins élevée sur une classe rare. Dans notre test, une seule erreur sur COAD réduit le rappel de cette classe de $1/7$, soit environ 14,29 points de pourcentage.




FIGURE 2 – Gènes 3 et 9176, sur l'entraînement.




FIGURE 3 – Gènes 9176 et 3540, sur l'entraînement.




FIGURE 4 – Gènes 1 et 2 : une séparation visuelle moins nette.

Certaines paires de variables font apparaître des groupes plus distincts que d'autres. Ces représentations suggèrent que les expressions géniques contiennent un signal utile à la classification. Elles ne suffisent toutefois pas à démontrer qu'une frontière particulière généralisera à de nouvelles observations. Les couples ci-dessus sont ceux conservés pour l'illustration exploratoire du projet.

1.2 Standardisation et normalisation

Pour les k -plus proches voisins, nous centrons et réduisons les variables après élimination des variables de variance presque nulle. Le calcul des distances dépend en effet de l'échelle des variables. Le fait que les valeurs aient un ordre de grandeur voisin ne suffit pas, à lui seul, à rendre la standardisation inutile.

Les arbres et les forêts sont appliqués aux expressions d'origine. L'ACP exploratoire est centrée mais non réduite ; elle privilégie donc les directions de plus grande variance sur l'échelle fournie. Ce choix décrit la représentation utilisée, sans prétendre qu'il soit optimal pour tous les modèles. Aucune nouvelle normalisation biologique des mesures RNA-Seq n'est réalisée dans ce notebook.

1.3 Analyse en composantes principales

L'Analyse en Composantes Principales (ACP) construit des combinaisons linéaires des variables qui expliquent successivement le plus de variance possible. Nous l'ajustons sur les 336 observations d'entraînement, après centrage, sans utiliser les étiquettes pour calculer les axes.




FIGURE 5 – Variance expliquée par chacune des 20 premières composantes.

La somme des parts de variance expliquée par les 20 premières composantes atteint **64,97 %**. Il s'agit d'une proportion de variance, et non d'une mesure directe de l'information utile à la classification. Une direction de faible variance peut encore contribuer à distinguer les classes.




FIGURE 6 – Projection de l'entraînement sur les deux premiers axes de l'ACP.

Le plan factoriel fait apparaître une structuration des observations, avec des recouvrements entre groupes. Les 20 composantes servent ici à décrire la variance ; la LDA, les voisins, les arbres et les forêts utilisent les variables géniques, avec leurs prétraitements respectifs. Dans le pipeline AdaBoost étudié plus loin, l'ACP conserve **10 composantes**, ajustées à l'intérieur de chaque pli de validation.

2 Une classe pour chaque tumeur

Nous cherchons maintenant à prédire l'une des cinq étiquettes : BRCA, COAD, KIRC, LUAD ou PRAD. Les scores qui suivent portent sur les mêmes 84 observations de test. Les paramètres des modèles sont choisis sur les 336 observations d'entraînement.

2.1 LDA

L'analyse discriminante linéaire constitue notre première référence. Elle recherche des frontières linéaires entre les classes. Le modèle est ajusté sur l'entraînement puis évalué sur le test ; son score sur les données utilisées pour l'ajuster ne remplace pas cette évaluation.




FIGURE 7 – Matrice de confusion de la LDA pour les cinq classes.

La LDA classe correctement **83 observations sur 84**, soit une accuracy de **98,81 %**. La seule erreur concerne une tumeur COAD prédite LUAD. Toutes les observations BRCA, KIRC, LUAD et PRAD du test sont correctement classées.

Indicateur	Valeur
Accuracy de test	0,9881
F_1 pondéré de test	0,9878
F_1 macro de test	0,9786
Accuracy moyenne en validation croisée sur l'entraînement	0,9970

La différence entre F_1 macro et pondéré rappelle le poids de la classe COAD, peu représentée. La LDA fournit ici une très bonne référence, sans que ce seul découpage permette d'affirmer sa supériorité générale. Ses coefficients peuvent être étudiés, mais leur interprétation est délicate lorsque les variables sont nombreuses et corrélées.

2.2 k -plus proches voisins

La méthode des k -plus proches voisins attribue à une observation la classe majoritaire parmi ses voisins dans l'ensemble d'entraînement. Nous utilisons une distance euclidienne après standardisation des expressions géniques. Le filtrage des variables presque constantes et la standardisation sont réappris dans chaque pli de validation.

Comme dans le projet initial, une première référence est construite avec $k = 10$. Elle classe correctement **82 observations sur 84**, soit une accuracy de **97,62 %**. Les courbes ROC sont calculées en opposant successivement chaque classe aux quatre autres.




FIGURE 8 – Courbes ROC du modèle de référence à $k = 10$ sur le test. Plusieurs courbes se superposent.

Les courbes sont proches du coin supérieur gauche, ce qui indique une bonne séparation selon les scores de ce modèle sur le test. Elles concernent toutefois le modèle de référence à $k = 10$ et ne doivent pas être présentées comme les courbes du modèle finalement retenu à $k = 20$.

Nous recherchons ensuite k parmi 1, 3, 5, 10 et 20. Le critère est fixé à l'avance : le F_1 macro moyen en validation croisée sur l'entraînement. La recherche sélectionne $k = 20$. Les résultats détaillés figurent sur la page suivante.

Une bonne courbe ROC ne signifie pas qu'aucune erreur de classification n'est possible. Elle évalue les scores sur plusieurs seuils, tandis que la matrice de confusion décrit les décisions effectivement prises par le classifieur.

k	F_1 macro moyen en CV	Écart-type entre plis
1	0,9896	0,0055
3	0,9896	0,0055
5	0,9928	0,0059
10	0,9918	0,0068
20	0,9950	0,0061




FIGURE 9 – Matrice de confusion du modèle retenu à $k = 20$.

Sur le test, ce modèle classe correctement **81 observations sur 84**. Une tumeur COAD, une tumeur KIRC et une tumeur PRAD sont prédites BRCA. Son accuracy vaut **96,43 %**, son F_1 pondéré 0,9643 et son F_1 macro 0,9616.

Le modèle à $k = 10$ commet une erreur de moins sur ce test. Cela n’annule pas le choix effectué en validation croisée : le test ne doit pas servir à choisir de nouveau k . Les écarts entre configurations sont faibles et leur classement peut varier avec les observations utilisées pour l’évaluation.

2.3 Arbres de décision, agrégation de forêts aléatoires

Les arbres construisent une succession de seuils portant sur les variables. Ils permettent de lire les règles de décision, sans standardisation préalable. Nous étudions d’abord un arbre de profondeur maximale 4, puis un arbre choisi par validation croisée, avant de passer à une forêt aléatoire.

Pour une classe donnée, vrais positifs, faux positifs et faux négatifs restent définis dans le problème multiclasse en opposant cette classe aux autres. Les moyennes macro et pondérée résument ensuite les indicateurs calculés classe par classe.




FIGURE 10 – Arbre de profondeur maximale 4, ajusté sur les 336 observations d’entraînement.

Dans les nœuds, les effectifs suivent l’ordre BRCA, COAD, KIRC, LUAD, PRAD. Cet arbre utilise **gene_18746**, **gene_219**, **gene_16358** et **gene_15896**. À la racine, le seuil $\text{gene_18746} \leq 10,65$ sépare notamment un groupe de 114 observations BRCA. L’une des feuilles contient encore 6 BRCA et 25 COAD : l’arbre de profondeur 4 ne sépare donc pas parfaitement l’entraînement.




FIGURE 11 – Expressions des quatre variables utilisées par l’arbre, en fonction de **gene_3**, sur l’entraînement.

Ces graphiques illustrent les différences d’expression exploitées par l’arbre. Les règles s’appliquent successivement à des sous-groupes ; une séparation peu nette sur l’ensemble des points peut être utile dans une branche donnée.




FIGURE 12 – Test : arbre de profondeur maximale 4.




FIGURE 13 – Test : arbre retenu par validation croisée.

Les deux arbres obtiennent la même matrice sur le test : **81 prédictions correctes sur 84**, soit **96,43 %**. Les erreurs sont COAD vers LUAD, KIRC vers COAD et PRAD vers COAD. Le F_1 pondéré vaut 0,9653 et le F_1 macro 0,9405 ; ce dernier met en évidence la précision plus faible de la classe COAD.

La grille explore les profondeurs maximales 4, 8 et sans limite, les tailles minimales de feuille 1, 4 et 8, ainsi que toutes les variables ou leur racine carrée à chaque séparation. Le meilleur réglage est **profondeur maximale 8, une observation minimale par feuille et toutes les variables candidates**.




FIGURE 14 – Arbre retenu : profondeur maximale autorisée 8, profondeur effectivement atteinte 5.

L'arbre ajoute une séparation sur **gene_6556** et classe parfaitement l'entraînement. Cet ajustement plus fin n'apporte aucun gain sur les 84 observations de test. Un meilleur ajustement des données d'entraînement ne garantit donc pas une amélioration de la généralisation.

Forêt aléatoire. La forêt combine 100 arbres. La grille retient une profondeur maximale de 5, une taille minimale de feuille de 1 et `max_features="sqrt"`. Elle classe correctement **83 observations sur 84**, comme la LDA. Sa seule erreur est une tumeur KIRC prédite BRCA.

	BRCA	COAD	KIRC	LUAD	PRAD
BRCA	30	0	0	0	0
COAD	0	7	0	0	0
KIRC	1	0	16	0	0
LUAD	0	0	0	16	0
PRAD	0	0	0	0	14
	BRCA	COAD	KIRC	LUAD	PRAD

FIGURE 15 – Matrice de confusion de la forêt aléatoire.

L'accuracy vaut **98,81 %**, le F_1 pondéré 0,9880 et le F_1 macro 0,9907. Ce dernier est plus élevé que celui de la LDA sur ce découpage, car l'erreur ne touche pas la petite classe COAD. Le score CV recalculé après sélection des paramètres reste un indicateur interne ; il ne constitue pas une évaluation indépendante de la recherche.

2.4 AdaBoost

Le pipeline associe un filtrage des variables presque constantes, une ACP à **10 composantes** et AdaBoost avec des arbres de profondeur maximale 3. L'ACP est réajustée dans chaque pli. La grille explore 100, 200 et 300 estimateurs, avec des taux d'apprentissage de 0,01, 0,1 et 1.

Le réglage retenu est **100 estimateurs et un taux de 0,1**. Il obtient **81 bonnes prédictions sur 84** : accuracy 96,43 %, F_1 pondéré 0,9640 et F_1 macro 0,9586. Il ne dépasse donc pas la LDA ou la forêt sur ce test.

	BRCA	COAD	KIRC	LUAD	PRAD
BRCA	30	0	0	0	0
COAD	0	6	0	1	0
KIRC	1	0	16	0	0
LUAD	0	0	0	16	0
PRAD	1	0	0	0	13
	BRCA	COAD	KIRC	LUAD	PRAD

FIGURE 16 – Matrice de confusion d'AdaBoost pour les cinq classes.

3 Seule contre tous

Nous regroupons maintenant les tumeurs COAD, KIRC, LUAD et PRAD dans une classe **OTHER**, afin de les opposer à BRCA. Les observations d'entraînement et de test restent exactement les mêmes ; seules les étiquettes changent. Le test comprend **30 BRCA et 54 OTHER**.




FIGURE 17 – Répartition des 420 observations : 150 BRCA et 270 OTHER.

La classe positive est **BRCA**. Une observation OTHER prédite BRCA est un faux positif ; une observation BRCA prédite OTHER est un faux négatif. Ce choix est appliqué à la précision, au rappel et au F_1 , indépendamment de l'ordre d'affichage des classes dans les matrices.

3.1 ACP

L'ACP est ajustée sur les mêmes expressions d'entraînement que précédemment ; seule la coloration des points change. La représentation permet d'examiner la position des BRCA par rapport aux autres tumeurs.




FIGURE 18 – Projection sur les deux premiers axes de l'ACP, avec les étiquettes BRCA et OTHER.

La projection fait apparaître une structure utile, mais une représentation à deux dimensions ne suffit pas à mesurer la qualité d'un classifieur. Les performances sont évaluées séparément sur le test et par validation croisée sur l'entraînement.

3.2 LDA

La LDA binaire classe correctement les **84 observations de test**. Elle obtient une accuracy, une précision BRCA, un rappel BRCA et un F_1 BRCA tous égaux à 1 sur ce découpage.




FIGURE 19 – LDA binaire : 30 BRCA et 54 OTHER correctement classées.

Le score moyen de validation croisée sur l'entraînement est **0,9957 pour le F_1 BRCA**. Le notebook imprimait encore l'intitulé *Accuracy moyenne* à cet endroit, alors que la fonction de score calcule bien un F_1 BRCA. Le libellé est corrigé dans ce rapport, sans modifier les prédictions.

3.3 k -plus proches voisins

Avec $k = 10$, le pipeline standardisé obtient déjà **83 bonnes prédictions sur 84**. La courbe ROC de BRCA ci-dessous décrit les probabilités produites par ce modèle.




FIGURE 20 – Courbe ROC de BRCA pour les k -plus proches voisins à $k = 10$.

La recherche utilise les mêmes valeurs candidates de k que pour les cinq classes, mais maximise cette fois le F_1 BRCA. Elle sélectionne également $k = 10$.

k	F_1 BRCA moyen en CV	Écart-type entre plis
1	0,9876	0,0101
3	0,9876	0,0101
5	0,9876	0,0101
10	0,9918	0,0100
20	0,9917	0,0102




FIGURE 21 – Matrice de confusion des voisins à $k = 10$, retenus en validation croisée.

Les **30 BRCA sont détectées**. Parmi les 54 OTHER, une observation est prédite BRCA. Le modèle compte donc 30 vrais positifs, un faux positif, aucun faux négatif et 53 vrais négatifs.

Indicateur sur le test	Valeur
Accuracy	0,9881
Précision BRCA	0,9677
Rappel BRCA	1,0000
F_1 BRCA	0,9836

Le rappel égal à 1 indique que toutes les BRCA de ce test sont reconnues. La précision inférieure à 1 signale qu'une prédiction BRCA est erronée. Le F_1 BRCA n'est donc pas identique à l'accuracy, même si les deux scores sont proches.

Les moyennes de validation de $k = 10$ et $k = 20$ sont presque égales. Cet écart minime ne permet pas de conclure à une supériorité stable d'un réglage ; il décrit seulement le résultat de la règle de sélection appliquée aux plis retenus.

3.4 Arbres de décision

Nous ajustons d'abord un arbre de profondeur maximale 4 sur les 336 observations d'entraînement. Sa profondeur réelle est 3. Il utilise `gene_18746`, `gene_4733` et `gene_13871`.




FIGURE 22 – Arbre binaire initial : profondeur maximale 4, profondeur réelle 3.

La première séparation utilise `gene_18746`, avec un seuil proche de 10,65. Sur l'entraînement, les 114 observations au-dessus de ce seuil sont BRCA. Six autres BRCA restent dans la branche opposée et nécessitent les séparations suivantes.




FIGURE 23 – Expression de `gene_18746` selon `gene_3` sur l'entraînement. Le trait pointillé indique le premier seuil de l'arbre.

Les noms affichés identifient des colonnes du jeu fourni. Ils ne constituent pas une annotation biologique permettant, à eux seuls, de désigner des biomarqueurs validés.




FIGURE 24 – Matrice de confusion de l'arbre binaire initial.

L'arbre classe correctement les **84 observations de test**. L'accuracy, la précision BRCA, le rappel BRCA et le F_1 BRCA valent tous 1. Il sépare aussi parfaitement l'entraînement, mais ces deux observations ont des significations distinctes : l'une décrit l'évaluation, l'autre l'ajustement.

Nous recherchons ensuite les hyperparamètres avec la même grille que dans le problème à cinq classes, en utilisant le F_1 BRCA comme critère. Le réglage retenu conserve une profondeur maximale de 4, mais impose au moins **4 observations par feuille**.

Paramètre ou résultat	Arbre initial	Arbre retenu
Profondeur maximale autorisée	4	4
Minimum d'observations par feuille	1	4
Variables candidates à chaque séparation	Toutes	Toutes
Profondeur réellement atteinte	3	2
Prédictions correctes sur le test	84/84	84/84

Le minimum de quatre observations par feuille empêche d'isoler la feuille d'une seule observation visible dans le premier arbre. Le modèle retenu devient donc plus simple : il n'utilise plus que **gene_18746** et **gene_4733**.

Sa feuille contenant 6 BRCA et 1 OTHER reste impure sur l'entraînement. Malgré cela, le score de test demeure identique. Cette comparaison montre qu'une séparation parfaite de l'entraînement n'est pas nécessaire pour obtenir ici une bonne performance de test.




FIGURE 25 – Arbre binaire retenu : profondeur réelle 2 et minimum de 4 observations par feuille.

Classe réelle	BRCA	30	0
	OTHER	0	54
		BRCA	OTHER
		Classe prédite	

FIGURE 26 – Matrice de confusion de l'arbre binaire retenu.

Forêt aléatoire dans le problème binaire. Le notebook évalue également une forêt de 100 arbres. La recherche retient une profondeur maximale de 5, une observation minimale par feuille et `max_features="sqrt"`. Comme la LDA et les deux arbres, elle obtient **84 prédictions correctes sur 84** ; sa matrice de confusion est identique à celle ci-dessus.

Les moyennes de validation croisée réimprimées après sélection sont arrondies à 1,00 dans le notebook. Cet arrondi ne permet pas de connaître leurs valeurs exactes. Ces scores ayant été calculés avec les paramètres sélectionnés sur le même entraînement, ils ne remplacent pas une évaluation de toute la procédure dans une validation croisée imbriquée.

3.5 AdaBoost

Le pipeline conserve la même structure que pour les cinq classes : filtrage des variables presque constantes, ACP à 10 composantes et arbres de profondeur maximale 3 dans AdaBoost. La validation croisée sélectionne cette fois **200 estimateurs avec un taux d'apprentissage de 0,01**.




FIGURE 27 – Matrice de confusion d’AdaBoost pour BRCA contre OTHER.

AdaBoost classe correctement **83 observations sur 84**. Il reconnaît les 54 OTHER, mais prédit OTHER pour une BRCA. Il compte donc **un faux négatif et aucun faux positif**, contrairement aux voisins, qui commettent un faux positif.

Modèle	Accuracy	Précision BRCA	Rappel BRCA	F_1 BRCA
LDA	1,0000	1,0000	1,0000	1,0000
Voisins, $k = 10$	0,9881	0,9677	1,0000	0,9836
Arbre initial	1,0000	1,0000	1,0000	1,0000
Arbre retenu	1,0000	1,0000	1,0000	1,0000
Forêt aléatoire	1,0000	1,0000	1,0000	1,0000
AdaBoost	0,9881	1,0000	0,9667	0,9831

L’accuracy seule ne décrit donc pas le type d’erreur commis : les voisins et AdaBoost ont le même nombre total d’erreurs, mais des précisions et des rappels différents. Le critère pertinent dépendrait d’un objectif d’utilisation défini au préalable.

Sur cette partition, AdaBoost n’apporte pas de gain par rapport aux modèles les plus simples. Le notebook ne fournit pas de comparaison systématique des temps de calcul ; il n’est donc pas possible de conclure ici à un avantage de rapidité mesuré.

4 Conclusion

Les modèles étudiés obtiennent de très bonnes performances sur le découpage considéré. Pour les cinq classes, la **LDA et la forêt aléatoire** atteignent 98,81 % de bonnes prédictions. La forêt obtient le meilleur F_1 macro observé, sans que cet écart suffise à établir une supériorité générale.

Modèle à cinq classes	Accuracy	F_1 pondéré	F_1 macro	Erreurs
LDA	0,9881	0,9878	0,9786	1
Forêt aléatoire	0,9881	0,9880	0,9907	1
Voisins, $k = 20$	0,9643	0,9643	0,9616	3
Arbre initial	0,9643	0,9653	0,9405	3
Arbre retenu	0,9643	0,9653	0,9405	3
AdaBoost	0,9643	0,9640	0,9586	3

Pour BRCA contre OTHER, la LDA, les arbres et la forêt ne commettent aucune erreur sur les 84 observations de test. Ce résultat décrit ce test précis : il ne signifie pas que ces modèles réussiront toujours, ni qu'ils sont validés pour une utilisation clinique. Les voisins et AdaBoost commettent chacun une erreur, de nature différente.

Limites de l'évaluation. Le test ne comprend que 84 observations ; une erreur représente environ 1,19 point d'accuracy. Les 7 observations COAD rendent les indicateurs de cette classe particulièrement sensibles à une erreur isolée. Les essais portent sur une même source de données, déjà explorée dans le projet, et aucune cohorte externe n'a été évaluée. Les coefficients et les règles portant sur des colonnes `gene_XX` ne démontrent pas une relation biologique causale.

Améliorations à poursuivre. Pour mesurer la stabilité de ces résultats, la priorité serait une **validation croisée imbriquée**, avec les mêmes plis externes pour comparer les méthodes et une recherche d'hyperparamètres répétée dans chaque entraînement interne. Cette procédure sépare la sélection des paramètres de son évaluation². L'utilisation des 801 observations pourrait ensuite être envisagée si les consignes du projet l'autorisent ; une validation sur une autre cohorte répondrait à une question différente, celle du transfert des résultats.

Les corrections de protocole et de présentation permettent de rendre compte des résultats actuels sans attendre ces expériences complémentaires. Les scores de validation et de test doivent rester distingués, le score CV de la LDA binaire doit être nommé F_1 BRCA, et les avertissements techniques répétitifs doivent être traités avant un nouvel export du notebook. Les valeurs rapportées ici restent celles de l'exécution fournie.

²Documentation scikit-learn, *Nested versus non-nested cross-validation*.